

GEMINI 429 ISSUES

Gemini 429 錯誤 根因分析與對策建議

429

Gemini Enterprise Agent Platform · 動態共用配額 (DSQ) 下的容量策略

RESOURCE_EXHAUSTED

2026 年 7 月 8 日

現況:配額一切正常, 429 照樣發生

0.02%

系統限制用量

us-central1 圖片輸入 RPM 上限 4,025
萬, 實際僅 7,791

無限制

Token 配額顯示值

flash-ga / flash-lite 四項配額全為 DSQ,
無固定數字

1.6 萬

每分鐘輸入 Tokens

flash-ga 實際流量(每日約 589 萬), 規模很小



結論:瓶頸不在專案配額。控制台看不到任何逼近上限的數字——429 來自模型 × 區域的「共用容量池」瞬時吃緊, 配額頁面永遠不會反映這件事。

實際案例：正式環境的 429 日誌

日誌重點 (Cloud Logging)

服務 image-data (Cloud Run / asia-east1)

專案 prod-image-rd (正式環境)

錯誤 google.genai ClientError: 429
RESOURCE_EXHAUSTED

場景 護照圖片辨識請求，以及微調模型預測

“Resource exhausted. Please try again later.”
= 即付即用 (DSQ) 架構的官方 429 訊息

事件時間軸 (6/18–6/29, 共 7 次)

6/18 11:58 圖片辨識 (第 13 張), 耗時 2.2s

6/24 13:12 圖片辨識 (第 2 張), 耗時 9.5s

6/25 10:32 / 16:24 圖片辨識 2 次, 耗時 10.1s / 11.4s

6/26 17:59 微調模型預測

6/29 16:23 / 16:33 圖片辨識 (10.7s) + 微調模型預測

初步判讀：12 天 7 次、全落在台灣上班時段、失敗前多有 9–11 秒等待——符合 DSQ 瞬時吃緊的間歇特徵，偏尖峰型。

根因:動態共用配額(DSQ)

傳統固定配額

額度歸屬 每專案固定數字(舊制示意, 與支出無關)

429 條件 自己的用量到頂才會發生, 可預期

控制台 用量百分比清楚可見, 可提前預警

調整方式 可提出配額提高要求(QIR)逐步擴充

DSQ(Gemini 2.0+ 預設)

額度歸屬 「模型 × 區域」全球所有客戶共用一池

429 條件 池子無餘裕即拒絕, 與自身用量無關

控制台 顯示「無限制」、百分比「-」, 無從預警

調整方式 沒有固定數字可調, 靠架構與 PT 應對

用量層級(Usage Tier): 依組織近 30 天支出分級。本組織月支出>\$2,000 = 級別 3(最高級):Flash 系列基準 1,000 萬 TPM/模型, 是效能地板而非天花板。但高優先通道門檻以「每秒」計、且以全域端點流量為準——單秒爆量仍會落入盡力而為通道。

何時容易撞上 429

熱門模型



2.5 Flash 等當紅模型競爭最激烈——實例顯示每小時 70-80 個請求就可能被拒，量小不代表安全

熱門區域



us-central1 是最擁擠的區域之一，而我們正在使用它

尖峰時段



美國上班時間全球需求最高，池子餘裕以秒為單位波動

大請求



長 context 單次需一次取得大量容量，比小請求更容易被拒

特徵：間歇性、無規律——DSQ 高優先通道的門檻以「秒」計，單秒爆量即被降級處理，平均量低不代表安全。第一步先抓 429 的時間分布，判定尖峰型或持續型。

社群現況：不是只有我們遇到

Google 開發者論壇近 12 個月共 49 篇「429 Resource Exhausted」相關討論，歸納五個共同樣態：

- 1 量小照樣中獎** 34 個請求就 429、配額剩 99.5% 仍被拒——低用量 429 是最大宗抱怨，官方回覆一律指向 DSQ + 重試 + PT
- 2 Preview／圖像模型最嚴重** 用量層級不保護預覽版模型，純靠搶；我們用的 2.5-flash 是 GA 模型，處境相對好
- 3 全域端點與重試都非保證** 有案例重試 10 次、跨 10 分鐘仍全數失敗——容量嚴重吃緊時，唯一的保證是 PT
- 4 新專案待遇更差** 同一模型舊專案正常、新專案持續 429：層級看消費歷史
- 5 2026 年 2–4 月起整體惡化** 討論量激增、出現數起區域級事件，與我們 7/7–7/9 的惡化趨勢吻合——共用池只會越來越擠

429 的官方機制 (SLA 觀點)

配額架構	錯誤訊息 / 行為	SLA 計算
即付即用(現況)	Resource exhausted, please try again later.	不計入錯誤率, 可重試
標準 PT(低於購買量)	容量問題轉為 5XX 回傳	計入 SLA 錯誤率(有保障)
單一可用區 PT(低於購買量)	容量問題轉為 5XX 回傳	不計入 SLA 錯誤率
PT(超過購買量)	超額請求自動改走即付即用(spillover)	依即付即用規則

官方建議的即付即用解法

1 優先使用全域端點

2 指數退避重試

3 平緩流量、消除尖峰

4 訂閱 PT 預留吞吐量

解法選項比較



流量平緩+退避

指數退避與抖動重試;客戶端限
速消除尖峰

成本:零

立即可做, 對間歇性尖峰最有效



批次 / Flex PayGo

可延後流量進佇列;Flex 接受
30 分內回應

成本: 5 折

微調預測等非即時工作適用



多區域分流

429 時自動改打其他允許區域
的端點

成本:低

僅限合規邊界內的區域



佈建輸送量(PT)

購買 GSU 預留吞吐量, 唯一的
容量保證

成本:高

適合關鍵業務的基載流量

採用順序: 由左至右, 先零成本再投資。官方組合配方: PT 保關鍵基載 → Priority PayGo 接尖峰 (僅全域端點) → 標準層級內跑一般流量 → 非關鍵工作走盡力而為突發。

合規資料夾下的限制：全域端點不可用



全域端點：官方首選，但我們不能用

- 不保證請求在哪個地理位置處理
- 資料落地 (data residency) 承諾僅涵蓋區域端點
- Assured Workloads 位置設定不含全域端點
- 資源位置組織政策很可能直接擋下 global 請求



合規邊界內的替代方案

- 邊界內多區域 failover: us-central1 被拒即改打 us-east4 等允許區域，效果接近全域端點
- 與合規負責人確認「允許區域清單」後實作
- 需要保證容量時，在合規區域內購買 PT

註記：優先隨用隨付 (Priority PayGo) 僅支援全域端點，在合規邊界內同樣不可用。費用面：Gemini 2.5 全域與區域端點同價；Gemini 3+ 正式版起 (2026/7/1) 區域端點貴 10%。

不建議的做法



開多個專案分流

- DSQ 池全客戶共用——拆專案是多個專案搶同一池，容量不會變多
- Usage Tier 以「組織」歷史消費計算，拆專案保障底線不變
- 服務條款明文禁止以多專案規避配額 (quota circumvention)
- IAM／監控／合規審查成本倍增，效益為零



跨合規邊界的代理專案

- 合規要求跟著「資料」走，不是跟著專案走
- 受管制資料借道外部專案＝把違規點搬到架構層
- VPC Service Controls 預設會擋跨專案呼叫
- 例外：非敏感工作負載分流、或去識別化後出境（需合規認定）

建議行動

短期 (1-2 週)

- 1 匯出並分析 429 時間分布: 尖峰型或持續型?
- 2 實作指數退避 + 抖動重試
- 3 客戶端流量平滑, 消除瞬間發射尖峰

中期 (本季)

- 1 可延後流量改走批次API
- 2 與合規確認允許區域清單
- 3 建立邊界內多區域 failover

長期

- 1 依業務關鍵性評估PT (GSU 用量規劃)
- 2 Gemini 3+ 升級時重新評估端點與成本策略 (區域+10%)

關鍵訊息



429 ≠ 專案配額用罄——是 DSQ 共用容量池的瞬時吃緊，控制台永遠看不到



先做零成本的重試與流量平滑，確認不足再投資批次、多區域與PT



所有架構調整以合規邊界為前提：全域端點與跨邊界代理都不可行

下一步：本週匯出 429 錯誤的時間分布數據，確定尖峰型或持續型，據此選擇投資路線

參考資料

Gemini Enterprise Agent Platform 配額和限制

docs.cloud.google.com/gemini-enterprise-agent-platform/machine-learning/quotas

錯誤代碼 429(官方排解指南)

docs.cloud.google.com/gemini-enterprise-agent-platform/models/deploy/error-code-429

標準版即付即用(Standard PayGo 用量層級)

docs.cloud.google.com/gemini-enterprise-agent-platform/models/standard-paygo

優先即付即用(Priority PayGo)

docs.cloud.google.com/gemini-enterprise-agent-platform/models/priority-paygo

生成式 AI 定價(全域／區域端點價格)

cloud.google.com/vertex-ai/generative-ai/pricing

部署與端點／資料落地(Data Residency)

docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/locations

官方部落格: Build a Robust and Cost-effective Gen AI Strategy (2026-04)

cloud.google.com/blog/products/ai-machine-learning/build-a-robust-and-cost-effective-gen-ai-strategy

Google 開發者論壇: 429 Resource Exhausted 社群討論(近 12 個月 49 篇)

[discuss.google.dev/search?q=429 Resources Exhausted](https://discuss.google.dev/search?q=429+Resources+Exhausted)

內部參考文件: *gemini-enterprise-agent-platform-配額和限制.md* (Gemini 429 Issues 專案知識庫)